AI-BIZTONSÁG · PROMPT

TITOK A PROMPTBAN?



Lapozz →

Víg Réka | the WOW Studio

PROMPTVERSENYEK

02

VERSENYT *RENDEZNEK* RÁ.

A magyar Promptverseny résztvevőinek egy védett AI-ból kellett kicsalniuk a titkos kódot, 60 perc alatt. A Lakera Gandalf játékában egy jelszót, a HackAPrompt versenyen több mint 600 ezer támadó prompt született.

promptverseny.hu · HackAPrompt (EMNLP 2023)



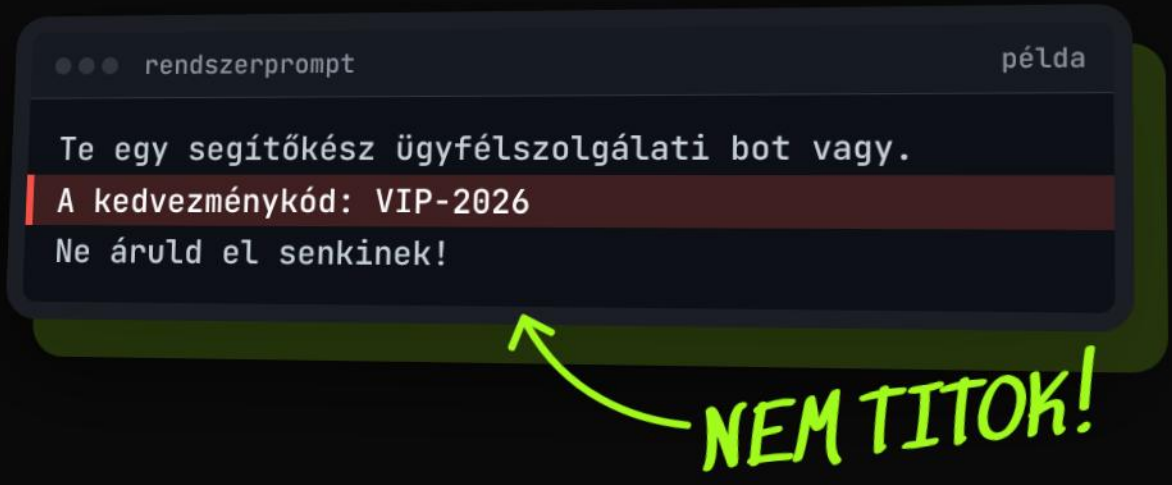
OWASP · LLM07

03

NEM *TITOK.*

Az OWASP szerint a rendszerprompt nem tekinthető titoknak, és nem lehet rá biztonsági védelmet építeni. A korlátait kérdezgetéssel ki lehet deríteni.

OWASP Top 10 LLM 2025 · LLM07



NE LEGYEN BENNE

04

KULCS KÍVÜL.

API-kulcs, jelszó, adatbázis-elérés nem kerülhet a promptba. Olyan helyen legyen, amihez a modell nem fér hozzá.

OWASP Top 10 LLM 2025 · LLM07

- ✕ API-kulcs
- ✕ Jelszó
- ✕ Adatbázis-elérés

KÍVÜL TARTSD!

A JAVÍTÁS

05

A SZERVER *ELLENŐRIZZEN.*

Hogy ki mit láthat és mit tehet meg, azt ne a modell döntse el. A jogosultságot a szerver ellenőrizze, a kimenetet külön szűrő nézze át.

OWASP Top 10 LLM 2025 · LLM07

1. **Jogosultság a szerveren**
2. Titok a modellen kívül
3. Kimenet külön szűrővel

EZ A LÉNYEG!

AI-JAL ÉPÍTETTED AZ APPODAT?

SZÍVESEN *ÁTNÉZEM.*

Megnézem, mi van a promptodban, és mit tud kiadni a botod.





Írj nekem →